

# Repaso

Basado en el curso de Ciencia de Datos con  
R Fundamentos Estadísticos


por

M. Sued, A. Bianco y M. Valdora

# Teoría de Probabilidades

1.  $S$  espacio muestral: conjunto con los posibles resultados del experimento.
2.  $A, B, C$ : eventos a los cuales vamos a asignarles probabilidad.
3.  $\mathbb{P}$ : función de probabilidad.

$$\frac{m_A}{m} \rightarrow \mathbb{P}(A)$$



$$m = 7$$
$$m_A = 3$$

$\mathbb{P}(A)$  representa el porcentaje de veces que esperamos que  $A$  ocurra en **infinitas** repeticiones

# Función de Probabilidad

$$0 \leq \mathbb{P}(A) \leq 1$$

La probabilidad del espacio muestral es uno:  $\mathbb{P}(\mathcal{S}) = 1$ .

Si  $A_1$  y  $A_2$  son eventos disjuntos ( $A_1 \cap A_2 = \emptyset$ ), entonces

$$\mathbb{P}(A_1 \cup A_2) = \mathbb{P}(A_1) + \mathbb{P}(A_2) .$$

$$\mathbb{P}(A^c) = 1 - \mathbb{P}(A).$$

Dados dos eventos  $A$  y  $B$ , tenemos que

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$$

# Concepto de Independencia

Dado un evento  $B$  con  $\mathbb{P}(B) > 0$ , definimos la probabilidad del evento  $A$  dado que  $B$  aconteció mediante la formula:

Probabilidad  
Condicional

$$\mathbb{P}(A \mid B) := \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$$

$A$  y  $B$  se dicen independientes si


$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$$

Lema: Si  $A$  y  $B$  son independientes y  $\mathbb{P}(B) > 0$ , entonces

$$\mathbb{P}(A \mid B) = \mathbb{P}(A)$$

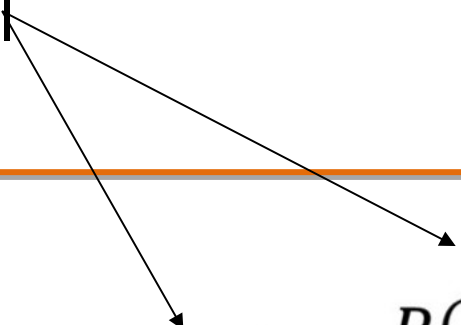
# Concepto de Independencia Condicional

$$\mathbb{P}(A \cap B \mid C) = \mathbb{P}(A \mid C)\mathbb{P}(B \mid C)$$



# Teorema de Bayes

Inversión del  
Condicional


$$P(A|B) = \frac{P(B|A) * P(A)}{P(B)}$$

$$P(A|B) = \frac{P(B|A) * P(A)}{P(B|A) * P(A) + P(B|\bar{A}) * P(\bar{A})}$$

# Variables Aleatorias

Una Variable Aleatoria  $X$  es una función definida sobre el espacio muestral que toma valores en los reales:

$$X : \mathcal{S} \rightarrow \mathbb{R}$$

Elementos del  
Espacio Muestral

Evento de Interes

Conjunto de  
valores de la  
Variable  
Aleatoria

$$X \in A = X^{-1}(A) = \{s \in \mathcal{S} : X(s) \in A\}$$

$$\mathbb{P}(X \in A) = \mathbb{P}(X^{-1}(A)) = \mathbb{P}(\{\omega \in \mathcal{S} : X(\omega) \in A\})$$


$$\mathbb{P}(X = t) = \mathbb{P}(X^{-1}(t)) = \mathbb{P}(\{\omega \in \mathcal{S} : X(\omega) = t\})$$

Valor puntual

# La Función de Distribución

La función de distribución acumulada  $F_X$  de la variable (aleatoria)  $X$  está definida por:

$$F_X : \mathbb{R} \rightarrow [0, 1] \quad F_X(t) = \mathbb{P}(X \leq t) = F(t)$$



1.  $0 \leq F_X(t) \leq 1$  para todo  $t \in \mathbb{R}$ .

2.  $F_X$  creciente: si  $s \leq t$ , entonces  $F_X(s) \leq F_X(t)$ .

3.  $\lim_{t \rightarrow -\infty} F_X(t) = 0$  y  $\lim_{t \rightarrow +\infty} F_X(t) = 1$ .

4.  $F_X$  es continua a derecha con límite a izquierda:

5.  $\mathbb{P}(X = a)$  es el salto en  $a$  de  $F_X$




# La Función de Densidad

Una variable aleatoria  $X$  se dice  $(*)$  absolutamente continua si existe una densidad

$$f_X : \mathbb{R} \rightarrow \mathbb{R}_{\geq 0}$$

tal que

$$\mathbb{P}(X \in A) = \int_A f_X(u) du.$$



En particular,

$$F_X(t) = \mathbb{P}(X \leq t) = \int_{-\infty}^t f_X(u) du .$$

En tal caso, diremos que  $f_X$  es la función de densidad de la variable aleatoria  $X$ .

$f : \mathbb{R} \rightarrow \mathbb{R}$  se dice densidad si

- $f(u) \geq 0$  para todo  $u \in \mathbb{R}$
- $\int_{-\infty}^{+\infty} f(u) du = 1$

# La Normal Univariada

- $Z$  normal estandar si


$$f_Z(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$$

- $f_Z$  simétrica en el origen:  $f_Z(z) = f_Z(-z)$
- Siendo  $f_Z$  simétrica, tenemos que  $F_Z(-u) = 1 - F_Z(u)$
- $F_Z(z) = \int_{-\infty}^z f_Z(u) du$  no se puede calcular.
- Hay tabla con valores de  $F_Z(u)$  para  $u > 0$ .
- $\phi(z) = F_Z(z)$  se llama función phi.

- $Z$  normal estandar, Sea  $X := \sigma Z + \mu$

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

- $F_X(x) = \phi((x - \mu)/\sigma)$
- $X \sim \mathcal{N}(\mu, \sigma^2)$



# Esperanza y Varianza

Dada una variable aleatoria discreta  $X$  con  $\mathbb{R}_g(X) = \{x_1, x_2, \dots\}$  y función de probabilidad puntual  $p_X(x_i)$ , definimos la esperanza de  $X$  mediante la fórmula,

$$\mathbb{E}[X] = \sum_{i=1}^{\infty} x_i p_X(x_i) ,$$

Dada una variable aleatoria continua  $X$  con función de densidad  $f_X$ , definimos la esperanza de  $X$  como

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} u f_X(u) du .$$

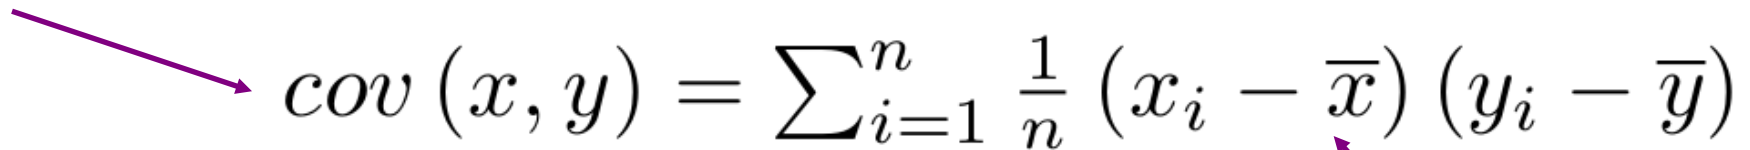
$X$  v.a.discreta con  $\mathbb{E}[X] = \mu$ . La varianza de  $X$ , está definida mediante la fórmula

$$\mathbb{V}(X) = \mathbb{E}\left[(X - \mu)^2\right] .$$

# Covarianza y Correlación

- Medidas de asociación lineal entre variables (x e y)

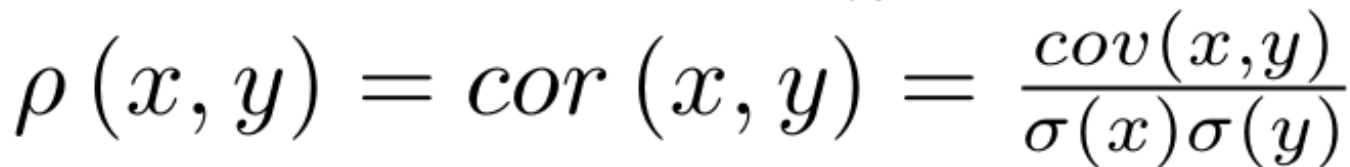
Covarianza Empírica



$$cov(x, y) = \sum_{i=1}^n \frac{1}{n} (x_i - \bar{x})(y_i - \bar{y})$$

The diagram shows a purple arrow pointing from the text 'Covarianza Empírica' to the formula. Another purple arrow points from the term  $(x_i - \bar{x})$  to the label 'Medias'. A third purple arrow points from the term  $(y_i - \bar{y})$  to the label 'Medias'.

Correlación



$$\rho(x, y) = cor(x, y) = \frac{cov(x, y)}{\sigma(x)\sigma(y)}$$

The diagram shows a purple arrow pointing from the text 'Correlación' to the formula. Another purple arrow points from the term  $cov(x, y)$  to the label 'Medias'. A third purple arrow points from the term  $\sigma(x)\sigma(y)$  to the label 'Desvios'.

Medias


-  $1 \leq \rho(x, y) \leq 1$

The diagram shows a purple arrow pointing from the label 'Desvios' to the term  $\sigma(x)\sigma(y)$  in the formula above.


Desvios

# Asociación Vs. Correlación

$\text{Cor}(x,y) = 0.9$



$\text{Cor}(x,y) = 0.05$



# Tchevichev

Sea  $W$  una v.a. con media  $\mu_W$  y  $V[W] = \sigma_W^2$ . Luego,  $\epsilon > 0$

$$\mathbb{P}(|W - \mu_W| \geq \epsilon) \leq \frac{\sigma_W^2}{\epsilon^2}$$

## Ley de los Grandes Números

Sean  $(X_i)_{i \geq 1}$  i.i.d., con  $E[X_i] = \mu$  y  $V[X_i] = \sigma^2$ , para todo  $i$ .  
Entonces, el promedio converge a  $\mu$  en probabilidad:

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\bar{X}_n - \mu| > \epsilon) = 0$$

Promedio


Es decir, para todo  $\epsilon > 0$ , vale que

$$\bar{X}_n \rightarrow \mu \text{ en probabilidad}$$

Valores de  
la Variable

# Ejemplo de Ley de los Grandes Números

Val	Prob
1	0.2
2	0.2
3	0.2
4	0.2
5	0.2



# Teorema Central del Límite

Variables  
Independientes e  
Identicamente  
Distribuidas

Sean  $(X_i)_{i \geq 1}$  v.a. i.i.d. con  $E[X] = \mu$  y  $V[X] = \sigma^2$ , entonces tenemos que

$$\mathbb{P}\left(\frac{\bar{X}_n - E(X_1)}{\sqrt{\text{Var}(\bar{X}_n)}} \leq x\right) \xrightarrow{n \rightarrow \infty} \phi(x) \quad \forall x \in \mathbb{R},$$

Promedio de  
Variables  
Aleatorias

Función de  
Distribución  
Normal




# Ejemplo del Teorema Central

$X_i$	$P(x_i)$
1	0.5
2	0.2
3	0.3



$(X_1 + X_2)/2$	$P((X_1 + X_2)/2)$
2/2	$0.5 * 0.5$
3/2	$0.5 * 0.2 + 0.2 * 0.5$
4/2	$0.5 * 0.3 + 0.2 * 0.2 + 0.3 * 0.5$
5/2	$0.2 * 0.3 + 0.3 * 0.2$
6/2	$0.3 * 0.3$



# Distribución de $(x_1+x_2+\dots+x_{20})/20$

Probabilidad

