

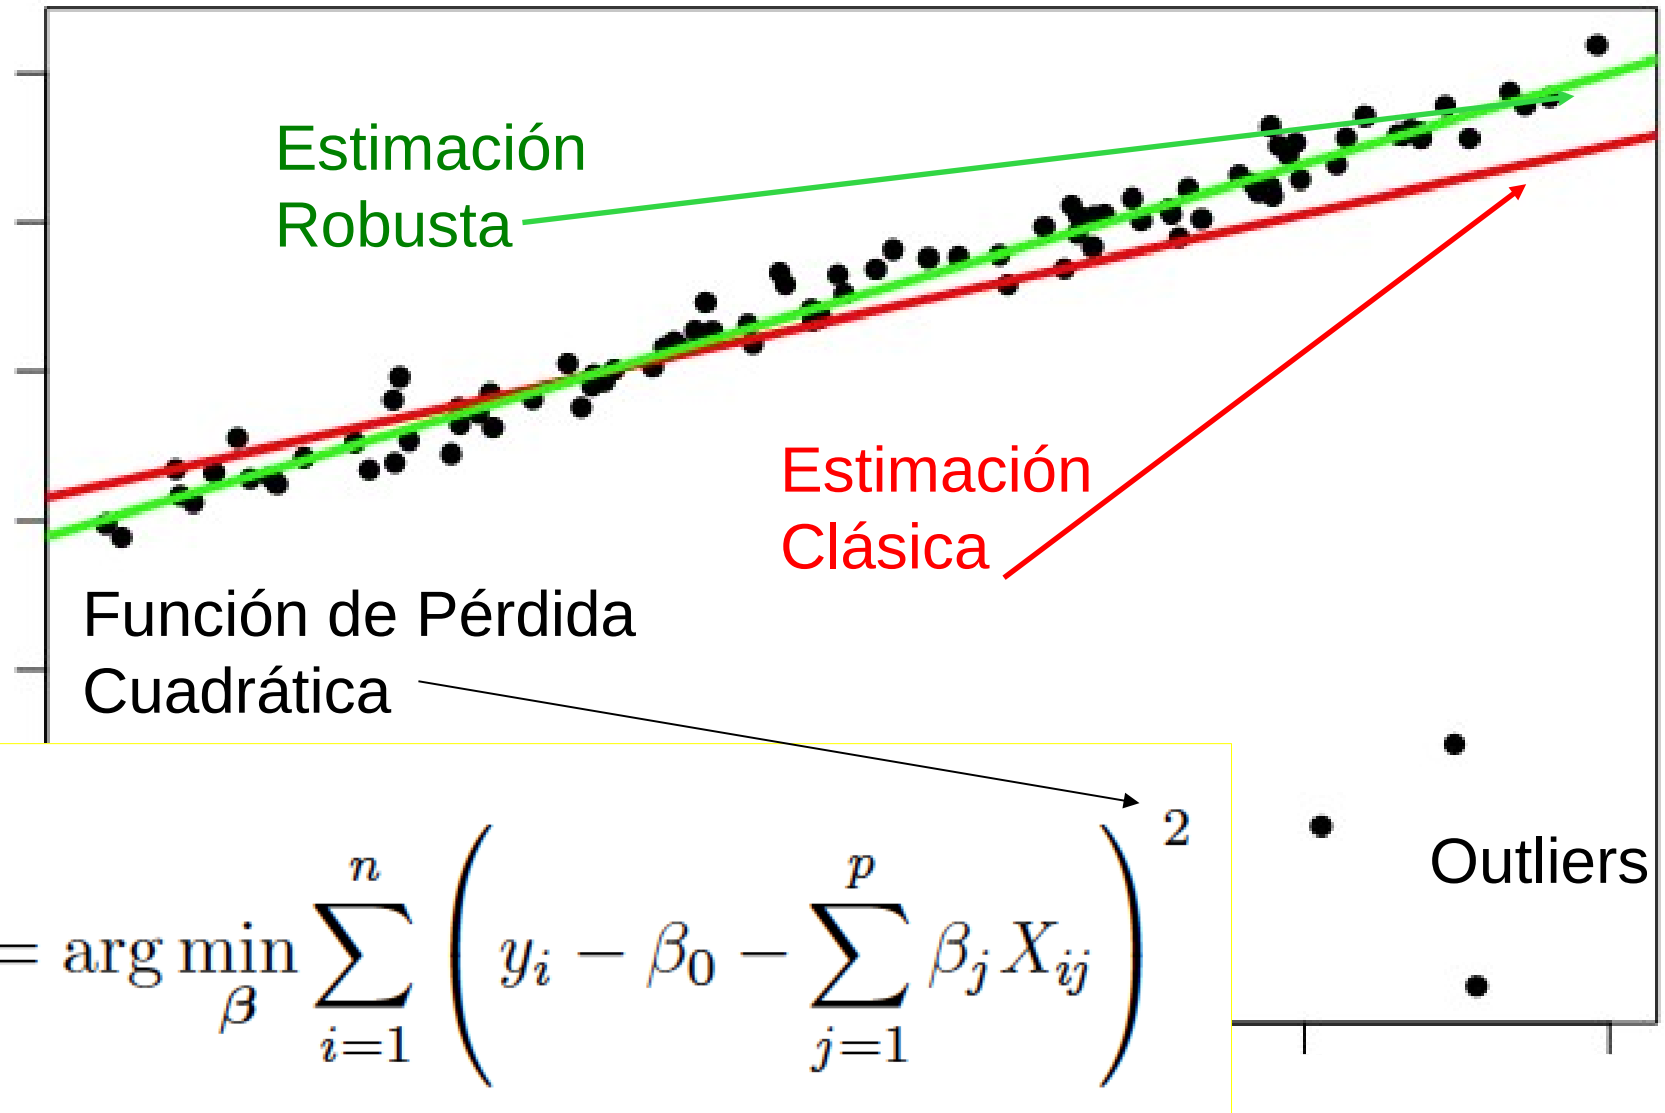
Robustez

Protección ante datos atípicos
(outliers)

La Importancia de la Robustez

- La información posee frecuentemente datos atípicos (**outliers**):
 - Mediciones erróneas
 - Mediciones extremas
- Los datos atípicos pueden **afectar** fuertemente el resultado de la aplicación de los métodos clásicos.
- Puede ser de interés la **detección** de los datos atípicos (Novelty detection).

El problema



Soluciones en Regresión

Valor absoluto — Estimador L1

$$\hat{\beta} = \arg \min_{\beta} \sum_{i=1}^n \left| y_i - \beta_0 - \sum_{j=1}^p \beta_j X_{ij} \right|$$


Mediana — Estimador LMS

$$\hat{\beta} = \arg \min_{\beta} \left\{ \text{med} \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j X_{ij} \right)^2 \right\}$$

Técnicas más Eficientes

M-Estimadores de Regresión

$$\hat{\beta} = \arg \min_{\beta} \sum_{i=1}^n \rho \left(\frac{y_i - \beta_0 - \sum_{j=1}^p \beta_j X_{ij}}{\hat{\sigma}} \right)$$



Estimador robusto de escala de los errores

Función de Huber

$$\rho(x) = \begin{cases} x^2 & \text{si } x \leq k \\ 2k|x| - k^2 & \text{si } x > k \end{cases}$$

Ecuaciones de estimación

Derivando se obtienen las ecuaciones des estimación para el estimador de mínimos cuadrados (ecuaciones normales):

$$\sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j X_{ij} \right) \mathbf{X}_i = 0$$

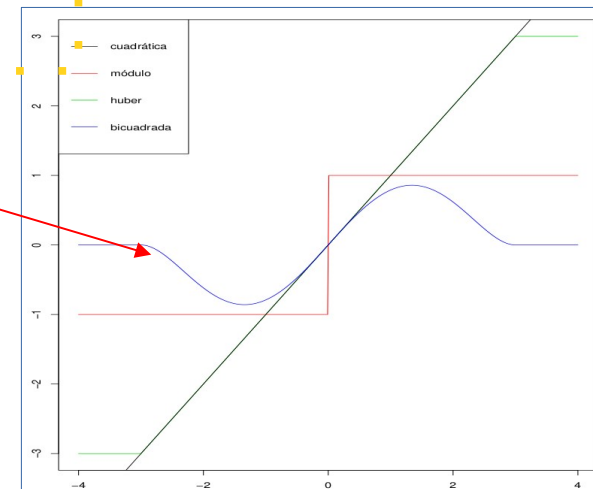
Los
parámetros
estimados
satisfacen esta
ecuación

para M-estimadores :

$$\sum_{i=1}^n \psi \left(\frac{y_i - \beta_0 - \sum_{j=1}^p \beta_j X_{ij}}{\hat{\sigma}} \right) \mathbf{X}_i = 0$$

donde $\psi = \rho'$

Derivada de la
Función de Pérdida



La ecuación

$$\sum_{i=1}^n \psi \left(\frac{y_i - \beta_0 - \sum_{j=1}^p \beta_j X_{ij}}{\hat{\sigma}} \right) \mathbf{X}_i = 0$$

es equivalente a

$$\sum_{i=1}^n \frac{\psi \left(\frac{y_i - \beta_0 - \sum_{j=1}^p \beta_j X_{ij}}{\hat{\sigma}} \right)}{y_i - \beta_0 - \sum_{j=1}^p \beta_j X_{ij}} \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j X_{ij} \right) \mathbf{X}_i = 0,$$

o sea

$$\sum_{i=1}^n W_i \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j X_{ij} \right) \mathbf{X}_i = 0,$$

con

$$W_i = \frac{\psi \left(\frac{y_i - \beta_0 - \sum_{j=1}^p \beta_j X_{ij}}{\hat{\sigma}} \right)}{y_i - \beta_0 - \sum_{j=1}^p \beta_j X_{ij}}$$

Nueva
ecuación de
estimación con
PESOS

Pesos
basados en la
ATÍPICIDAD
de las obs.

Es la ecuación de un estimador de mínimos cuadrados pesados con pesos desconocidos. Se resuelve por un métodos iterativos: IRWLS.

Implementación en R

- Rlm (MASS)
- rq (quantreg)
- lmRob (robust)
- lmrob (robustbase)

<https://cran.r-project.org/web/views/Robust.html>

CRAN Task View: Robust Statistical Methods

Regularización (Shrinkage)

Regresión con Penalización
Ridge y Lasso

Regularización, para que se usa ?

- En general, es una técnica para prevenir el **Overfitting**, mediante la penalización de la complejidad del modelo.
- Controla los desbalances entre el número de observaciones y el número de variables.
- Como método automático de selección de variables (Lasso).
- Reduce la alta variabilidad observada en situaciones de **multicolinealidad** (Ridge).
- Cuidado ! Reduce la Varianza pero Aumenta el **Sesgo** de los estimadores !
- Cuidado ! No son equivariantes por cambios de escala ! Hay que **estandarizar** las variables !

Regresión Ridge

Parámetro de Penalización

Penalización cuadrática (L2)

$$\hat{\beta} = \arg \min_{\beta} \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p \beta_j^2$$

Falta de Ajuste

Penalización,
encoge los
coeficientes
hacia el CERO
(Shrinkage)

Propiedades del Estimador Ridge

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$$

Distinto de CERO y
creciente (en modulo
) con Lambda

$$\text{Bias}(\hat{\beta}) = -\lambda \mathbf{W} \beta$$

Decreciente con
Lambda

$$\text{Var}(\hat{\beta}) = \sigma^2 \mathbf{W} \mathbf{X}^T \mathbf{X} \mathbf{W}$$

Matriz Inversible
(SIEMPRE)

$$\mathbf{W} = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1}$$

Resultado Sorprendente !!!


- Siempre existe un valor del parámetro de penalización tal que el MSE de Ridge es estrictamente menor que el MSE de OLS.

$$\exists \lambda > 0 \quad MSE_{\hat{\beta}_\lambda}^{RIDGE} < MSE_{\beta}^{OLS}$$


- Como se elige el Lambda óptimo
??????Validación Cruzada

Ejemplo de Ridge Regression


Predicción de Lluvia



Elección de Lambda (Deviance)



Elección del Lambda (Error Clasificación)



Lasso Regression

- Puede usarse como método de **selección** de variables

Parámetro de Penalización


Penalización lineal (L1)

$$\hat{\beta} = \arg \min_{\beta} \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p |\beta_j|$$


Falta de Ajuste

Penalización, encoge los coeficientes hacia el CERO. Convierta a algunos coeficientes en CERO


Ejemplo de Regresión Lasso




Elección de Lambda (Deviance)



Elección del Lambda (Error Clasificación)



Ridge y Lasso - Intuición Geométrica



El Paquete “glmnet”

Parámetro de Elasticnet

`glmnet` solves the following problem

$$\min_{\beta_0, \beta} \frac{1}{N} \sum_{i=1}^N w_i l(y_i, \beta_0 + \beta^T x_i) + \lambda \left[(1 - \alpha) \|\beta\|_2^2 / 2 + \alpha \|\beta\|_1 \right],$$

over a grid of values of λ covering the entire range. Here $l(y, \eta)$ is the negative log-likelihood contribution for observation i ; e.g. for the Gaussian case it is $\frac{1}{2}(y - \eta)^2$. The *elastic-net* penalty is controlled by α , and bridges the gap between lasso ($\alpha = 1$, the default) and ridge ($\alpha = 0$). The tuning parameter λ controls the overall strength of the penalty.